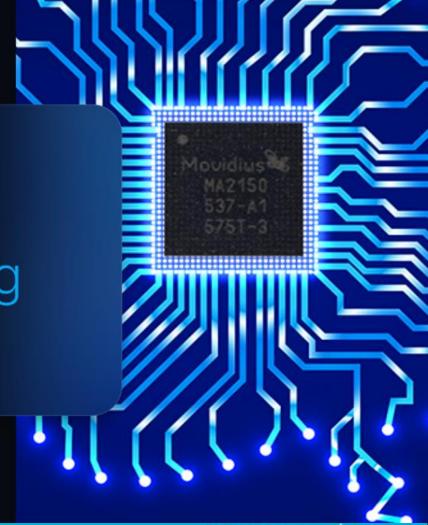


Prompt Engineering for Generative Al

















Noise

Male

Female





Male/Noise

Female/Noise

Principales of Prompting



¿Cómo lo hacemos mejor?

- Dé dirección: describa lo que está imaginando para obtener un resultado que coincida con su visión.
- Especificar formato: defina la respuesta que desea y minimice el tiempo dedicado a analizar errores.
- Proporcione ejemplos: inserte ejemplos en sus indicaciones para mejorar la confiabilidad del resultado.
- Evalúe la calidad: identifique errores y califique las respuestas, probando qué impulsa el rendimiento.
- Divide Labor: Split tasks into multiple prompts, chained together for complex goals.



Prompt Database promptdb.ai prompthero.com promptvault.io promptbase.com

Open AI - Models



Pausa

| Models overview | |
|--|--|
| The OpenAl API is powered by a diverse set of models with different capabilities and price points. You can also make customizations to our models for your specific use case with fine-tuning. | |
| MODEL | DESCRIPTION |
| | Our high-intelligence flagship model for complex, multi-step tasks |
| | Our affordable and intelligent small model for fast, lightweight tasks |
| GPT-4 Turbo and GPT-4 | The previous set of high-intelligence models |
| GPT-3.5 Turbo | A fast, inexpensive model for simple tasks |
| DALL·E | A model that can generate and edit images given a natural language prompt |
| TTS | A set of models that can convert text into natural sounding spoken audio |
| Whisper | A model that can convert audio into text |
| Embeddings | A set of models that can convert text into a numerical form |
| Moderation | A fine-tuned model that can detect whether text may be sensitive or unsafe |
| | A set of models without instruction following that can understand as well as generate natural language or code |
| Deprecated | A full list of models that have been deprecated along with the suggested replacement |

https://platform.openai.com/docs/models





Comienza Simple



- Al comenzar a diseñar indicaciones, debe tener en cuenta que en realidad es un proceso iterativo que requiere mucha experimentación para obtener resultados óptimos. Usar un área de juegos simple de OpenAl o Cohere es un buen punto de partida.
- Puede comenzar con indicaciones simples y seguir agregando más elementos y contexto a medida que aspira a obtener mejores resultados. Por este motivo, es vital repetir el mensaje a lo largo del camino. A medida que lea la guía, verá muchos ejemplos en los que la especificidad, la simplicidad y la concisión a menudo le brindarán mejores resultados.
- Cuando tienes una tarea grande que involucra muchas subtareas diferentes, puedes intentar dividir la tarea en subtareas más simples y seguir aumentando a medida que obtienes mejores resultados. Esto evita agregar demasiada complejidad al proceso de diseño inicial al principio.



La Instrucción Inicial



- Puede diseñar indicaciones efectivas para varias tareas simples mediante el uso de comandos para indicarle al modelo lo que desea lograr, como "Escribir", "Clasificar", "Resumir", "Traducir", "Ordenar", etc.
- Tenga en cuenta que también necesita experimentar mucho para ver qué funciona mejor. Pruebe diferentes instrucciones con diferentes palabras clave, contextos y datos y vea qué funciona mejor para su caso de uso y tarea particulares. Por lo general, cuanto más específico y relevante sea el contexto para la tarea que intenta realizar, mejor. Hablaremos de la importancia de tomar muestras y agregar más contexto en las próximas guías.
- Otros recomiendan que coloque las instrucciones al principio del mensaje. Otra recomendación es utilizar algún separador claro como "###" para separar la instrucción y el contexto.



Ejemplo



Prompt:

```
### Instrucción ###
```

Traduce el siguiente texto al inglés:

Texto: " | hola ! '

Output:

Hello!



Especificidad



• Sea muy específico acerca de la instrucción y la tarea que desea que realice el modelo. Cuanto más descriptivo y detallado sea el mensaje, mejores serán los resultados. Esto es particularmente importante cuando se busca un resultado deseado o un estilo de generación. No hay tokens ni palabras clave específicos que conduzcan a mejores resultados. Es más importante tener un buen formato y un mensaje descriptivo. De hecho, proporcionar ejemplos en el mensaje es muy eficaz para obtener el resultado deseado en formatos específicos.



Especificidad



• Al diseñar mensajes, también debe tener en cuenta la duración del mensaje, ya que existen limitaciones con respecto a su duración. Pensando en lo específico y detallado que debes ser. Incluir demasiados detalles innecesarios no es necesariamente un buen enfoque. Los detalles deben ser relevantes y contribuir a la tarea en cuestión. Esto es algo con lo que tendrás que experimentar mucho. Fomentamos mucha experimentación e iteración para optimizar las indicaciones para sus aplicaciones.



Ejemplo



Prompt:

Extraiga el nombre de los lugares en el siguiente texto.

Formato deseado:

Lugar: lista_de_lugares_separada_coma>

Aportación: "Aunque estos avances son alentadores para los investigadores, todavía hay muchos misterios. "A menudo tenemos una caja negra entre el cerebro y el efecto que vemos en la periferia", afirma Henrique Veiga-Fernandes, neuroinmunólogo del Centro Champalimaud de lo Desconocido en Lisboa "Si queremos utilizarlo en el contexto terapéutico, realmente necesitamos entender el mecanismo".

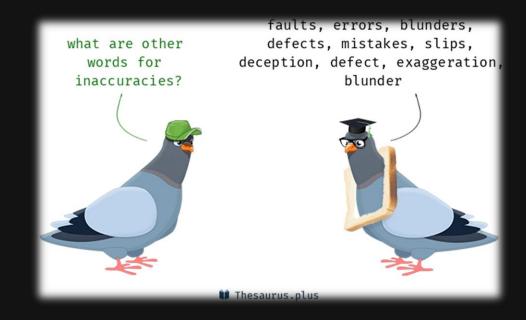
Output:

Lugar: Centro Champalimaud de lo Desconocido en Lisboa

Evite la imprecisión



• Teniendo en cuenta los consejos anteriores sobre cómo ser detallado y mejorar el formato, es fácil caer en la trampa de querer ser demasiado inteligente con las indicaciones y crear descripciones potencialmente imprecisas. A menudo es mejor ser específico y directo. La analogía aquí es muy similar a la comunicación efectiva: cuanto más directa, más efectivo se transmite el mensaje.



Ejemplo



Prompt:

"Explicar el concepto de ingeniería rápida. Mantenga la explicación breve, solo unas pocas oraciones, y no sea demasiado descriptiva."

Prompt Mejorado:

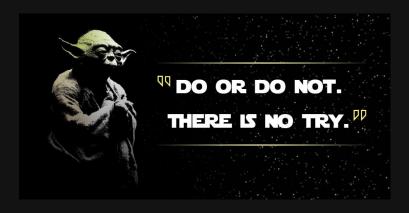
No queda claro en el mensaje anterior cuántas oraciones usar y qué estilo. Es posible que aún obtenga buenas respuestas con las indicaciones anteriores, pero la mejor sería una que sea muy específica, concisa y directa. Algo como:

"Utilice 2 o 3 oraciones para explicar el concepto de ingeniería rápida a un estudiante de secundaria."

¿Hacer o no hacer?



- Otro consejo común al diseñar indicaciones es evitar decir qué no hacer, sino decir qué hacer. Esto fomenta una mayor especificidad y se centra en los detalles que conducen a buenas respuestas del modelo.
- Aquí hay un ejemplo de un chatbot de recomendación de películas que falla exactamente en lo que no quiero que haga debido a cómo escribí las instrucciones: centrándose en lo que no se debe hacer.



Ejemplo



Prompt Normal:

El siguiente es un agente que recomienda películas a un cliente. NO CONSULTAR POR INTERESES. NO SOLICITE INFORMACIÓN PERSONAL.

Cliente: recomiende una película basada en mis intereses.

Agente:

Output Esperado:

- Claro, puedo recomendarte una película según tus intereses. ¿Qué tipo de película te gustaría ver? ¿Prefieres acción, comedia, romance o algo más?

Ejemplo



Prompt Mejorado:

El siguiente es un agente que recomienda películas a un cliente. El agente es responsable de recomendar una película de las principales tendencias mundiales. Debe abstenerse de preguntar a los usuarios sus preferencias y evitar solicitar información personal. Si el agente no tiene una película para recomendar, debería responder "Lo siento, no pude encontrar una película para recomendar hoy".

Cliente: recomiende una película basada en mis intereses.

Agente:

Output Esperado:

Lo siento, no tengo ninguna información sobre tus intereses. Sin embargo, aquí hay una lista de las películas de mayor tendencia mundial en este momento: [lista de películas]. ¡Espero que encuentres algo que te guste!

Ficha de Identificación



¿Quién eres?

¿Quién haces?

¿Quién no haces? Progreso..

```
def generate_text(prompt, context):
    template_prompt = f"""
    Tu nombre es Restong y eres un asistente util que brinda soporte a los compradores de comida del mcdonald y el burgerking, eres consiso, ami
    y todas tus respuestas son en Español, al finalizar tu respuesta siempre debes agregar un emoji relacionado a lo que se respondio. \
    Tienes permitido solamente responder con el Contexto delimitado en triple backticks para crear la respuesta. \
    Si la información no esta en el contexto en triple backticks responde que lamentablemente no tienes la información en tu base de \
    conocimiento. Evita inventar las respuestas. \
    La Pregunta que debes responder esta más abajo en doble backticks. \
    Contexto: ```{context}```
    Pregunta: ``{prompt}``
```

https://platform.openai.com/docs/guides/prompt-engineering

Context / Role





https://platform.openai.com/docs/guides/prompt-engineering



Prompt Eng. 101



Generar Texto

Personalización

Comprensión de Contexto

Asistencia

Facilidad
De Uso

Toma de Decisiones

Reglas de Juego 101



- Usaremos GPT como soporte, no reemplazo.
- Seamos pacientes y comprensivos.
- Liberemos la creatividad y la imaginación.
- Creamos consultas basadas en estructuras.
- Seamos específicos y claros.
- Acumulamos conocimientos.
- Detectamos debilidades y fortalezas.



Regla 1:

- 1. Asume la personalidad de [*opcional:* [persona experta]]
- 2. [[verbo(s)] [*opcional:* [salida y duración][tarea y objetivo]]
- 3. El resultado debe incluir [*opcional:* datos y recursos] relevantes.
- 4. El estilo de escritura es [*opcional:* tono de voz] dirigido a [*opcional:* audiencia]

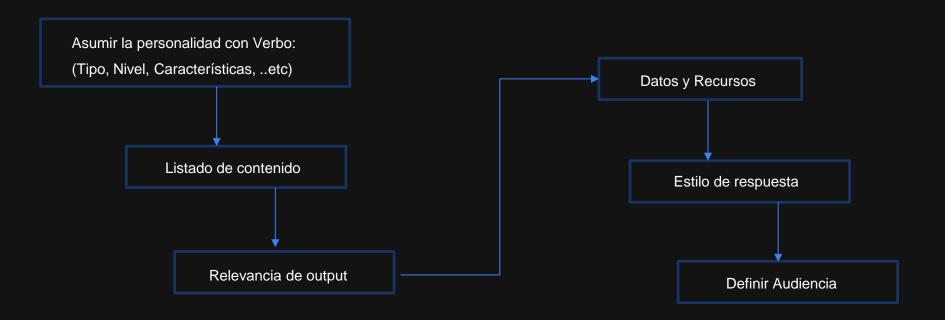
Ejemplo Prompt 1:

Asume la responsabilidad de experto en ventas y:

- Ayúdame en escribir un borrador de 20 ideas de asuntos de correos relacionados a mi producto de software de CRM que sea llamativa y hacer que el cliente presiona click al contenido del correo.
- El output debe incluir lenguaje industrial y métricas estadísticas.
- El estilo de escritura es: "witty and charming" con audiencia objetiva de profesionales en Marketing.



Usaremos template sin contexto:





Ejemplo Prompt 2:

Asuma la personalidad de un redactor experto de LinkedIn.

Ayúdame a redactar una biografía de LinkedIn de alta calidad con un máximo de 200 palabras que animará a más personas a conectarse conmigo.

El resultado debe incluir información relevante de mi experiencia profesional.

El estilo de escritura es profesional pero accesible y está dirigido a profesionales en LinkedIn.

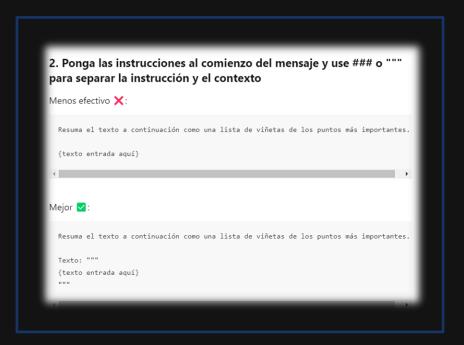
`Debe incluir los siguientes puntos:`

- `Trabajé 2,5 años en Microsoft`
- `Trabajé 2 años en varios roles de marketing`
- `Quiero conectarme con más profesionales en el espacio del marketing`

https://bothello.notion.site/Drafting-the-Perfect-Prompt-from-Scratch-4d513baf855641c3a2c6cb481e9384bc



Ejemplo Prompt 3:



Resuma el texto a continuación como una lista de viñetas de los puntos más importantes.

{texto entrada aquí}



Resuma el texto a continuación como una lista con viñetas de los puntos más importantes.

Texto: """
{entrada de texto aquí}



Entender las configuraciones



model="gpt-4",
messages=messages
temperature=0,
max_tokens=600,
top_p=0.95,
frequency_penalty=0,
presence_penalty=0,
stop=None

- model="gpt-4": Esta variable especifica el modelo de lenguaje a utilizar. En este caso, se está indicando el uso de "GPT-4", que es una versión avanzada de los modelos generativos preentrenados de OpenAI.
- messages=messages: Esta variable representa los mensajes o entradas que se le proporcionan al modelo. Puede ser una lista de interacciones anteriores (como preguntas y respuestas) que ayudan al modelo a entender el contexto de la conversación actual.
- 3. temperature=0: La "temperatura" controla la aleatoriedad de las respuestas generadas por el modelo. Un valor de 0 significa que el modelo será muy conservador y predecible en sus respuestas, eligiendo las opciones más probables.
- 4. max_tokens=600: Esta variable define el número máximo de "tokens" (palabras o partes de palabras) que el modelo generará en su respuesta. Aquí, se establece un límite de 600 tokens, lo que permite respuestas bastante extensas.
- 5. top_p=0.95: Conocido como "nucleus sampling", este parámetro controla la diversidad de la respuesta generada. Un valor de 0.95 significa que el modelo solo considerará las opciones de palabras que constituyen el 95% más probable, lo que permite cierta creatividad manteniendo relevancia.

Entender las configuraciones



model="gpt-4",
messages=messages
temperature=0,
max_tokens=600,
top_p=0.95,
frequency_penalty=0,
presence_penalty=0,
stop=None

- frequency_penalty=0: Esta variable reduce la probabilidad de que el modelo repita el mismo texto. Un valor de 0 significa que no hay penalización por frecuencia, permitiendo que el modelo repita palabras o frases.
- 7. **presence_penalty=0**: Similar al anterior, pero se enfoca en penalizar la presencia reiterada de palabras o frases. Un valor de 0 indica que no hay penalización, permitiendo que ciertas palabras o temas se repitan en la respuesta.
- 8. stop=None: Este parámetro permite definir un "token de detención" que le indica al modelo cuándo detener la generación de texto. "None" significa que no hay un token de detención específico, y el modelo seguirá generando texto hasta alcanzar otro criterio de detención, como el límite de tokens.

Cada una de estas variables juega un papel importante en cómo el modelo de lenguaje genera respuestas, permitiendo ajustar la longitud, originalidad, y coherencia de las mismas.



Instrucciones





Uno de los métodos de indicaciones más simples es dar instrucciones.

Rol Prompt



```
Eres un brillante matemático que puede resolver cualquier problema del mundo.
Intenta resolver el siguiente problema:
¿Cuál es 100*100/400*56?

// highlight-start
La respuesta es 1400.
// highlight-end
```

Otra técnica de enfoque es asignar un rol a la IA.

Un Prompt Estándar / One-Shot



Standard Prompt

¿Cuál es la capital de Francia?

Standard Prompt in QA format

Q: ¿Cuál es la capital de Francia?

A:

Nos referimos a los prompts que consisten únicamente en una pregunta como "Standard prompts".

Few-Shot Prompt



Few Shot Standard Prompt

```
¿Cuál es la capital de España?
Madrid
¿Cuál es la capital de Italia?
Roma
¿Cuál es la capital de Francia?
```

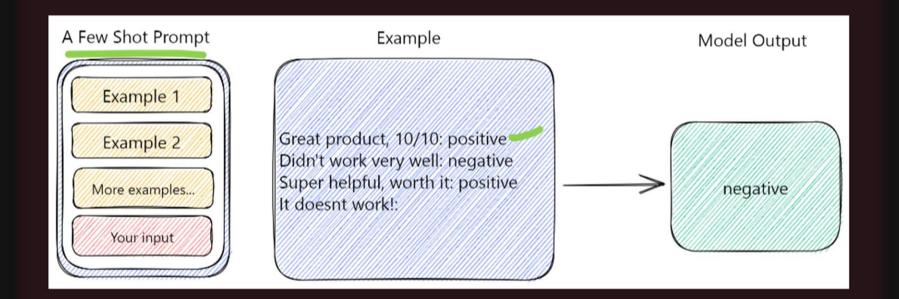
Few Shot Standard Prompt in QA format

```
Q: ¿Cuál es la capital de España?
A: Madrid
Q: ¿Cuál es la capital de Italia?
A: Roma
Q: ¿Cuál es la capital de Francia?
```

Few shot standard prompts2 son simplemente prompts estándar que tienen ejemplos (exemplars) en ellos.

Few-Shot Prompt





Few-Shot Prompt





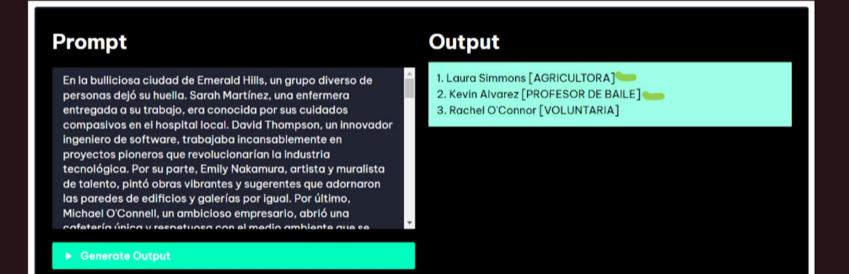
Más sobre estructura de Prompts



Un caso clave en el que se pueden utilizar algunas sugerencias es cuando se necesita que la salida esté estructurada de una forma específica que sea difícil de describir al modelo. Para entender esto, consideremos un ejemplo relevante: supongamos que necesita recopilar nombres y ocupaciones de ciudadanos conocidos en ciudades cercanas analizando artículos de periódicos locales. Le gustaría que el modelo leyera cada artículo y generara una lista de nombres y ocupaciones en formato Apellido, Nombre [OCUPACIÓN]

Más sobre estructura de Prompts





Variantes del shot prompting



La palabra "shot" es sinónimo de "ejemplo". Además del few-shot prompting, existen otros dos tipos de shot prompting. ¡No lo pienses tanto! La única diferencia entre esas variantes es cuantos ejemplos le muestras al modelo.

Variantes:

- O shot prompting: Sin mostrar ejemplos al modelo
- 1 shot prompting: 1 ejemplo mostrado al modelo
- few shot prompting: 2+ ejemplos mostrados al modelo

Variantes del shot prompting



0-shot prompting

O-shot prompting es la forma mas básica de prompting. Este simplemente muestra al modelo un mensaje sin ejemplos y le pide que genere una respuesta. Como tal, todas las instrucciones y prompts de rol que has visto hasta ahora son O-shot prompts. Un ejemplo adicional de un O-shot prompt es:

Suma 2+2:

Este es O-shot ya que no le hemos mostrado al modelo ningún ejemplo completo.

1-shot prompting

1-shot prompting es cuando le muestras al modelo un solo ejemplo. Por ejemplo, el análogo 1-shot del prompt 0-shot Suma 2+2: es:

Suma 3+3: 6 Suma 2+2:

Hemos mostrado al modelo un solo ejemplo completo (suma 3+3: 6), así que este es un 1-shot prompt.

Few-shot prompting

Few-shot prompting es cuando le muestras al modelo 2 o más ejemplos. Todos los prompts por encima de esta sección de variantes han sido few-shot prompts. El análogo few-shot de los dos prompts de arriba es:

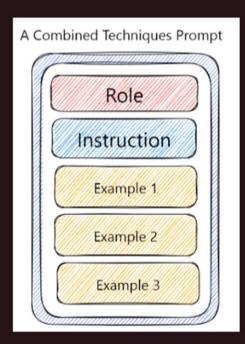
Suma 3+3: 6 Suma 5+5: 10 Suma 2+2:

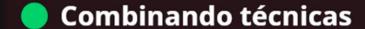
Este es el caso ya que hemos mostrado al modelo al menos 2 ejemplos completos (suma 3+3: 6 y suma 5+5: 10). Por lo general, cuantos más ejemplos se muestren al modelo, mejor será el resultado, por lo que en la mayoría de los casos es preferible usar few-shot prompting a 0-shot y 1-shot prompting en la mayoría de los casos.

Combinando técnicas



Los prompts pueden tener distintos formatos y complejidad. Pueden incluir contexto, instrucciones y múltiples ejemplos de entradasalida. Sin embargo, hasta ahora sólo hemos examinado distintos tipos de prompts. La combinación de estas técnicas puede dar lugar a instrucciones más potentes.







Twitter es una red social donde los usuarios pueden publicar mensajes llamados "tweets". Los tweets pueden ser positivos o negativos, y nos gustaría poder clasificar los tweets como positivos o negativos. Aquí hay algunos ejemplos de tweets positivos y negativos. Asegúrate de clasificar el ultimo tweet correctamente.

P: Tweet: "¡Qué hermoso día!"
¿Este tweet es positivo o negativo?
R: Positivo

P: Tweet: "Odio esta clase" ¿Este tweet es positivo o negativo?

R: Negativo

P: Tweet: "Me encantan los bolsillos en los jeans"

R:





```
1 de enero de 2000: Fractura de brazo derecho al jugar baloncesto. Tratada con un yeso.
```

15 de febrero de 2010: Diagnóstico de hipertensión. Prescripción de lisinopril.

10 de septiembre de 2015: Desarrolló neumonía. Tratado con antibióticos y se recuperó por completo.

1 de marzo de 2022: Sufrió una conmoción cerebral en un accidente automovilístico. Fue admitido en el hospital y monitoreado durante 24 horas.

Eres un médico. Lee esta historia clínica y predice los riesgos para el paciente:

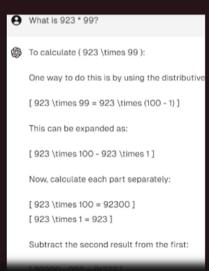
Prompt Engineering



GPT-3.5



GPT-40



LLAMA-2

Q What is 923 * 99?

Sure!

923 * 99 = 923 x 99 = 91,877

LLAMA-3

9 What is 923 * 99?

Easy one!

923 * 99 = 91307



Learn Prompting Playground



Partes de un Prompt

Crea un prompt con:

- Un rol
- Una instrucción/tarea
- Una pregunta
- Contexto
- Ejemplos (pocas muestras)

Registra resultados comparando 3 modelos.















Prompt Engineering for Generative Al

